RELATÓRIO DE PROJETO · ANÁLISE DE DADOS

Dashboard de Gastos Governamentais — CPGF

Como identificar padrões de gasto, despesas atípicas e oportunidades de fiscalização sem confundir anomalia com irregularidade.

79.984	R$ 41,48 mi	201	90,3%
transações analisadas	gasto total	prioridade alta	recall do detector

Niel Hart · Studio Hart

SQL Server · Python · Power BI · Painel web

13 de outubro de 2026 · Dados simulados no formato oficial do CPGF

1. Resumo

Dados simulados. O Portal da Transparência estava inacessível no ambiente de desenvolvimento (erro 403). Todos os números deste relatório vêm de uma base fictícia no formato oficial do CPGF, com órgãos, pessoas e fornecedores inventados. O código aceita os CSVs oficiais sem alteração.

O projeto entrega um pipeline completo de análise do CPGF que separa **atipicidade** de **irregularidade**: 79.984 transações (R$ 41,48 mi) viraram uma fila de 201 itens de prioridade alta (R$ 777,4 mil), cada um com a regra que disparou e as explicações legítimas possíveis.

1.122	201	60	408
transações com indício (1,40%)	prioridade alta · R$ 777,4 mil	unidades gestoras	fornecedores

- **Entregáveis:** painel web interativo, 4 scripts SQL Server, pipeline Python, guia Power BI (modelo, Power Query, DAX) e README.
- **Base de teste:** 8 órgãos superiores, jan/2025 a set/2026, com 766 anomalias plantadas e gabarito.
- **Resultado do detector:** recall de 90,3% e precisão de 61,7% sobre as anomalias plantadas.

2. Passo a passo do projeto



Pipeline do projeto · 5 etapas. Cada etapa existe em SQL Server e em Python; o contexto legítimo reduz o score antes de o item entrar na fila.

3. Problemas reais resolvidos

Quatorze problemas apareceram no caminho; os seis primeiros vêm da própria base do CPGF e valem também para os arquivos oficiais.

#	Problema	Impacto medido	Solução	Resultado
1	Mês do extrato diferente do mês da transação	23.565 linhas (29,5%)	Análise temporal pela data da transação	Série mensal coerente
2	Favorecido sigiloso ou sem informação	1.494 sigilosos · 2.559 sem informação	Fora do ranking e da regra de concentração	Ranking não distorcido
3	Estornos (valor negativo)	601 linhas	Mantidos no gasto líquido, fora das regras de compra	Estorno não vira alerta
4	Linhas repetidas sem ID da transação	60 linhas idênticas	Sinalizadas, nunca removidas	Compra legítima preservada
5	Arquivo em ISO-8859-1, `;` e vírgula decimal	100% das linhas	Leitura como texto e conversão controlada	0 valores e 0 datas inválidos
6	Saques sem favorecido	1.949 saques (R$ 711 mil)	Categoria própria e regra de saque redondo	Saque analisado à parte
7	Fim de exercício parecia crescimento anormal	Nov/dez 26,3% acima dos outros meses; dez +50% sobre nov	Tom destacado e comparação com o mesmo mês do ano anterior	Sazonalidade não é anomalia
8	Falsos positivos em hospitais e forças	8.868 compras de fim de semana	Unidade 24h entra como contexto antes do alerta	Nenhuma gerou alerta
9	Regra de valor extremo ruidosa	929 disparos · 3,8% de precisão	Desvio robusto em log (mediana e MAD) por ramo	151 disparos · 23,2% · 100% das plantadas
10	Portal da Transparência inacessível (403)	Sem dado oficial	Base simulada no formato real, semente fixa e gabarito	Detector medido contra 766 casos
11	SQL com agrupamento errado e dependência de configuração	View de ramo agrupava por valor; fim de semana dependia de DATEFIRST	Mediana em CTE; fórmula independente de DATEFIRST; parâmetros em tabela	Regras iguais em qualquer servidor
12	Gráfico mensal com rótulos sobrepostos	Visto na renderização	Escala refeita e conferida por captura de tela	Leitura limpa em 21 meses
13	Erro de tipo no pandas ao preencher o ramo	Pipeline parava	Preenchimento por série alinhada ao índice	Pipeline roda de ponta a ponta
14	Itens com score zerado fora da contagem de atípicos	4 itens (1.120 em vez de 1.122)	A classe passou a definir o que é atípico	Contagem igual em todos os arquivos

4. Atipicidade não é irregularidade

Cada regra aponta um padrão que merece contexto; só a apuração documental (nota fiscal, finalidade, ato de autorização) distingue erro, exceção autorizada e irregularidade.

Regra	Peso	O que detecta	Explicações legítimas
R1 Fracionamento	3	3 ou mais compras no mesmo dia, mesmo portador e fornecedor, todas logo abaixo do limite	Reposição recorrente; limite do cartão no dia
R2 Saque redondo	2	Saque de R$ 1.500 ou mais, múltiplo de 100	Pronto pagamento autorizado
R4 Valor extremo	2	Valor muito acima do típico do ramo	Equipamento pontual; erro de digitação
R5 Concentração	2	Um fornecedor com mais de 35% do gasto mensal da unidade	Ata de registro de preços; fornecedor único
R3 Fim de semana	1	Compra em sáb/dom em unidade que não opera 24h	Plantão; evento; data de processamento
R6 Duplicidade	1	Mesmo portador, fornecedor, valor e dia	Erro de carga ou compra idêntica legítima

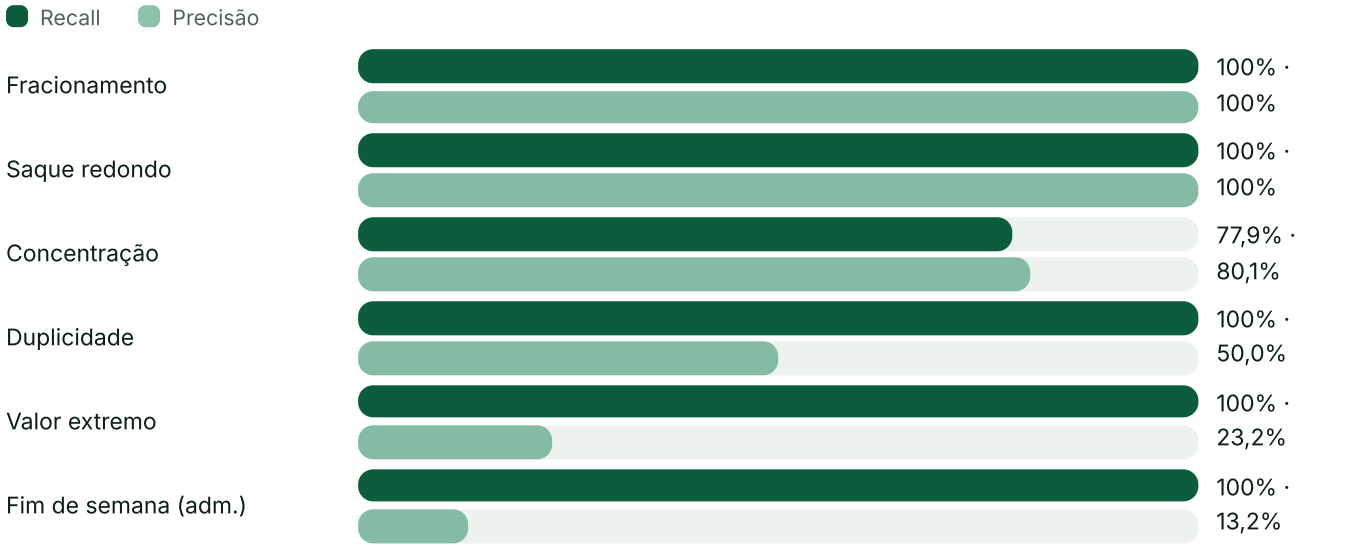
O contexto estrutural (fim de exercício, evento anual cadastrado, unidade 24h) reduz o score em 2 pontos antes da triagem:

- ▲ Prioridade alta score 3 ou mais depois do ajuste · 201 transações · R$ 777,4 mil.
- ● Observar score 1 ou 2 · 917 transações.
- ◆ Contexto provável havia indício, mas existe explicação estrutural conhecida · 4 transações.

> Títulos e cores do painel evitam “fraude” e “irregular”. Vermelho só para prioridade alta, sempre com ícone e rótulo; cada alerta mostra as explicações inocentes possíveis e o que verificar.

5. Validação do detector

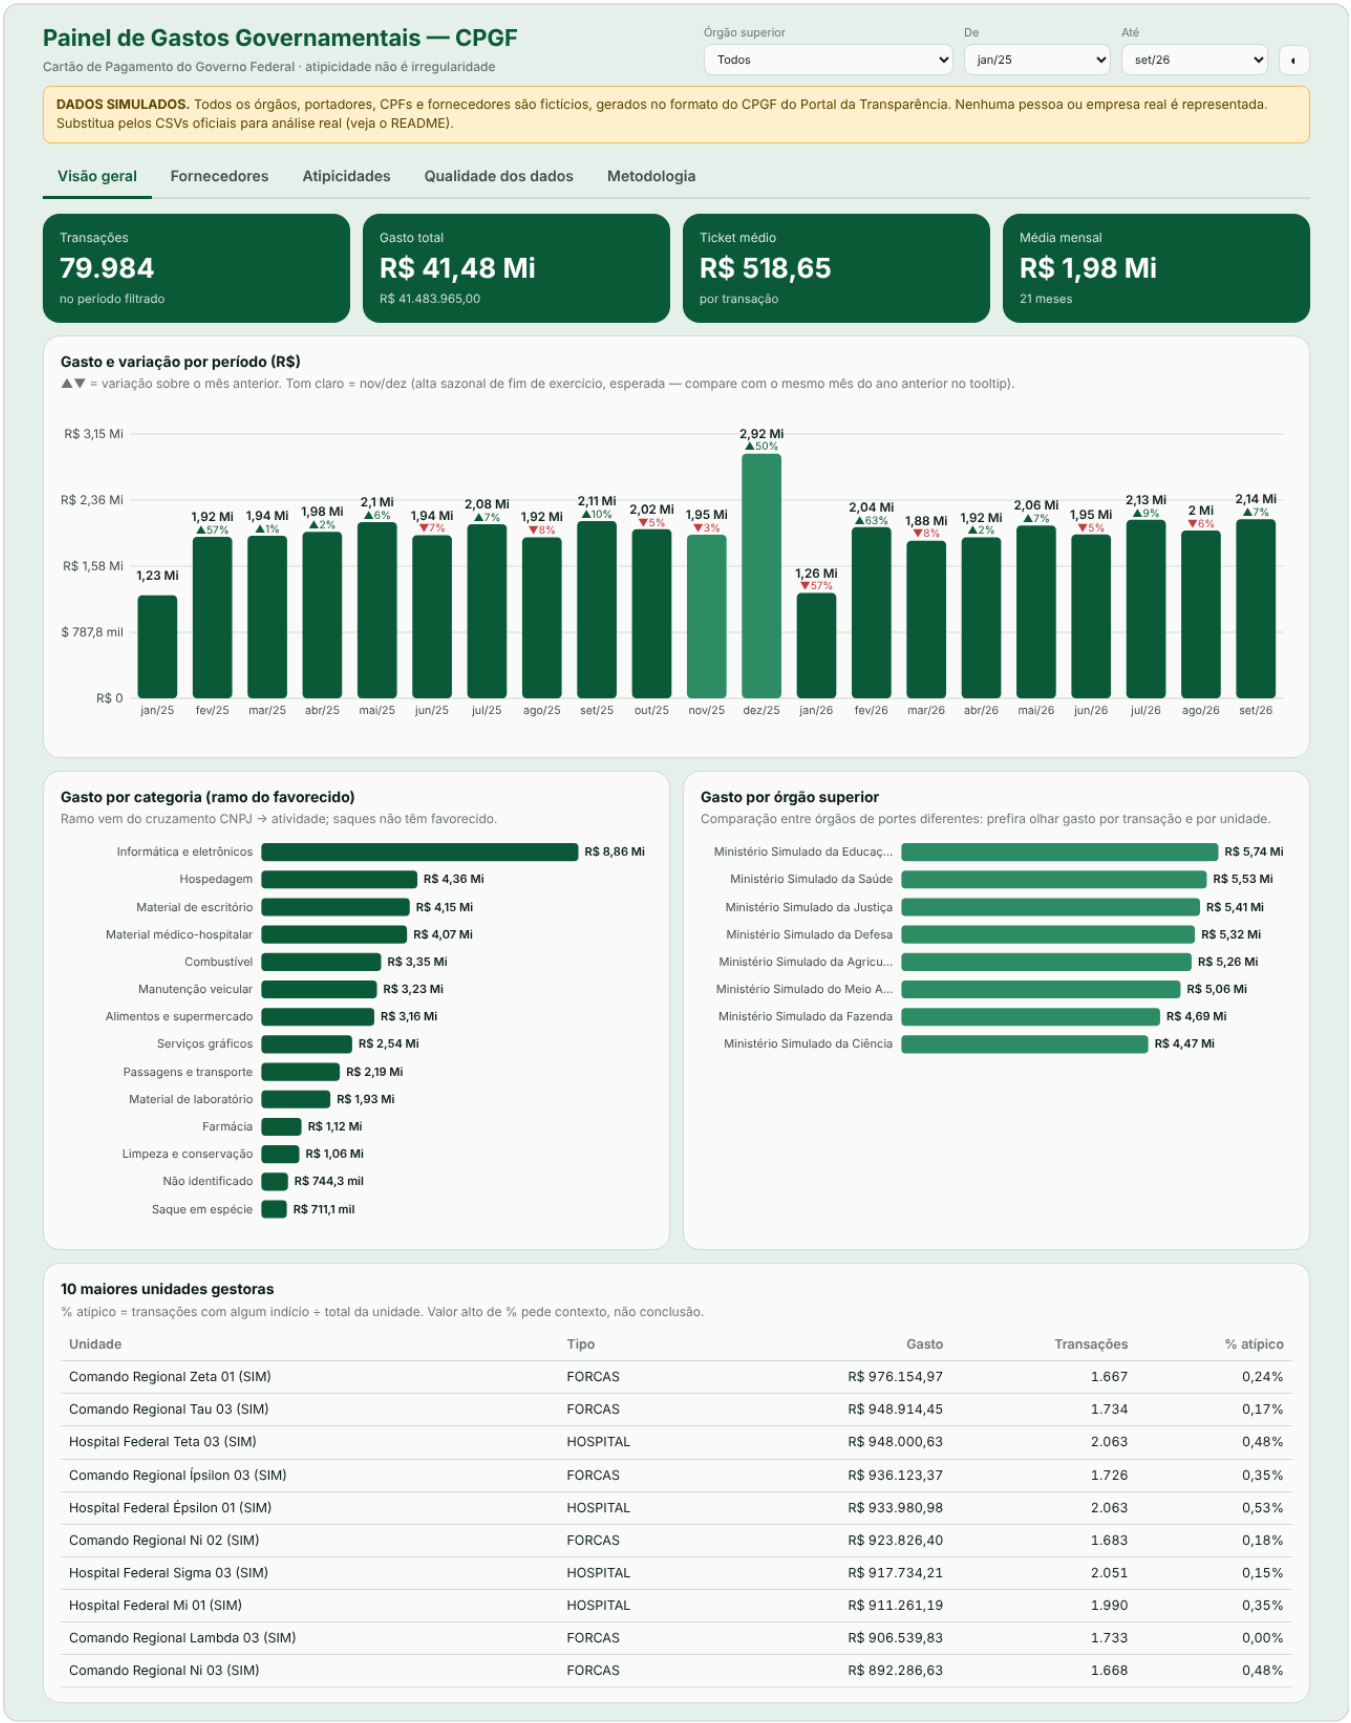
Com 766 anomalias plantadas, o detector acerta 90,3% (recall) e 61,7% do que sinaliza é plantado (precisão). A precisão baixa em duas regras é esperada: a base normal também produz fins de semana e valores altos legítimos, por isso a saída é uma fila de triagem.



Tipo plantado	Plantadas	Detectadas	Recall	Disparos	Precisão
Fracionamento	173	173	100,0%	173	100,0%
Saque redondo	40	40	100,0%	40	100,0%
Concentração	403	314	77,9%	392	80,1%
Duplicidade	60	60	100,0%	120	50,0%
Valor extremo	35	35	100,0%	151	23,2%
Fim de semana (administrativa)	55	55	100,0%	416	13,2%

A correção da regra de valor extremo (problema 9) subiu a precisão geral de 41,7% para 61,7% ao custo de 2,9 pontos de recall (de 93,2% para 90,3%).

6. O painel



Visão geral: gasto e variação por período (nov/dez em tom claro), categoria, órgão e maiores unidades.

Painel de Gastos Governamentais — CPGF

Cartão de Pagamento do Governo Federal · atipicidade não é irregularidade

Órgão superior: Todos | De: jan/25 | Até: set/26

DADOS SIMULADOS. Todos os órgãos, portadores, CPFs e fornecedores são fictícios, gerados no formato do CPGF do Portal da Transparência. Nenhuma pessoa ou empresa real é representada. Substitua pelos CSVs oficiais para análise real (veja o README).

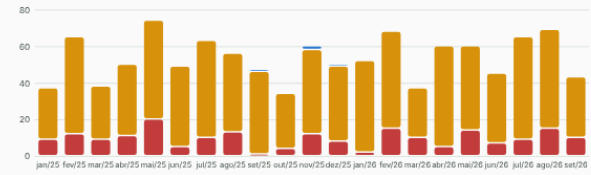
Visão geral | Fornecedores | Atipicidades | Qualidade dos dados | Metodologia

Transações com indício	Prioridade alta	Observar	Contexto provável
1.122	201	917	4
1,40% do total	R$ 777,4 mil envolvidos	R$ 1,41 Mi	explicação estrutural conhecida

Como ler: cada alerta é uma **hipótese de trabalho**. O painel mostra a regra que disparou, o contexto legítimo que já foi considerado e as explicações inocentes plausíveis. Só a apuração (nota fiscal, finalidade, ato de autorização) distingue erro, exceção autorizada e irregularidade.

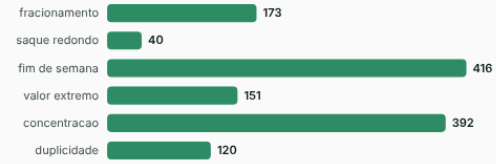
Alertas por mês e classe

Prioridade alta | Observar | Contexto provável



Disparos por regra

Passe o mouse para ver as hipóteses legítimas da regra.



Fila de investigação (600 maiores scores)

Classe: Todas | Regra: Todas | Busca: unidade, fornecedor, portador | 600 alertas

Data	Unidade	Favorecido	Valor	Classe	Regras
18/08/2026	Instituto Federal Épsilon 02 (SIM)	DISTRIBUIDORA SOL NASCENTE LTDA Limpeza e conservação	R$ 3.939,10	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO R5_CONCENTRACAO
18/04/2025	Instituto Federal Delta 01 (SIM)	MERCADINHO UNIÃO EIRELI Alimentos e supermercado	R$ 3.917,28	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO R5_CONCENTRACAO
01/07/2025	Superintendência Teta 01 (SIM)	SUPERMERCADO HORIZONTE EIRELI Alimentos e supermercado	R$ 3.911,50	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO R5_CONCENTRACAO
18/02/2026	Superintendência Sigma 02 (SIM)	SUPERMERCADO IMPERIAL S/A Alimentos e supermercado	R$ 3.883,56	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO R5_CONCENTRACAO
10/09/2026	Superintendência Iota 01 (SIM)	AUTO POSTO SOL NASCENTE LTDA Combustível	R$ 3.874,48	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO R5_CONCENTRACAO
18/02/2026	Superintendência Sigma 02 (SIM)	SUPERMERCADO IMPERIAL S/A Alimentos e supermercado	R$ 3.864,31	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO R5_CONCENTRACAO
11/02/2026	Centro de Pesquisa Iota 02 (SIM)	HIGIENE PLANALTO EIRELI Limpeza e conservação	R$ 3.855,73	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO R5_CONCENTRACAO
18/08/2026	Instituto Federal Épsilon 02 (SIM)	DISTRIBUIDORA SOL NASCENTE LTDA	R$ 3.851,72	▲ Prioridade alta score 7	R1_FRACIONAMENTO R4_VALOR_EXTREMO

Mostrando 150. Use os filtros ou abra `out/fila_investigacao.csv` para a lista completa.

Validação do detector (só existe na base simulada)

766 anomalias foram plantadas com gabarito. Recall geral 90,3% · precisão geral 61,7%.

Tipo plantado	Plantadas	Detectadas	Recall	Disparos da regra	Precisão
fracionamento	173	173	100,0%	173	100,0%
saque redondo	40	40	100,0%	40	100,0%
fim de semana adm	55	55	100,0%	416	13,2%
valor extremo	35	35	100,0%	151	23,2%
concentracao	403	314	77,9%	392	80,1%
duplicidade	60	60	100,0%	120	50,0%

Precisão baixa é esperada: a base normal também gera atipicidades legítimas (fim de exercício, eventos, hospitais 24h). Esse é o ponto: alerta ≠ irregularidade. Em fim de semana e valor extremo a precisão é baixa porque a base normal também produz casos assim — exatamente por isso a saída é uma **fila de triagem**, não uma lista de culpados.

Atipicidades: alertas por mês e classe, disparos por regra e fila de investigação com hipóteses legítimas.

7. Limites e próximos passos

Limites

- Os scripts SQL foram escritos para SQL Server 2019 ou superior, mas não foram executados no ambiente de desenvolvimento; as contagens precisam ser conferidas contra a saída em Python.
- A base pública não traz nota fiscal, finalidade nem autorização: o painel gera hipóteses, não provas.
- Sem ID da transação, duplicidade não distingue erro de carga de compra repetida.
- A regra de concentração recupera 77,9% das plantadas; a de pico mensal por unidade não foi implementada.
- O arquivo do Power BI (.pbix) não foi gerado; há um guia com modelo, Power Query e medidas DAX.

Próximos passos

1. Baixar os CSVs mensais do Portal da Transparência e rodar o pipeline com `--entrada`.
2. Montar a dimensão de ramo (CNPJ para CNAE) e a de contexto das unidades.
3. Ajustar o limite por compra à norma vigente e calibrar pesos com quem conhece a rotina dos órgãos.
4. Executar os scripts SQL e comparar as contagens com o Python.
5. Montar o .pbix seguindo o guia e publicar o repositório no GitHub.

Relatório gerado a partir do repositório cpgf-dashboard. Alertas são hipóteses de trabalho; só a apuração documental distingue erro, exceção autorizada e irregularidade.